

Используя библиотеки `sklearn` и `torch`, в зависимости от датасета решите следующие задачи классификации (мультиклассификации) или регрессии. Графики рисуйте с помощью библиотеки `matplotlib` или любой другой удобной библиотеки (например, `seaborn`)

1. Нормализуйте текст
2. Разбейте его на трейн/тест. Если датасет слишком большой, то оставьте не больше 10к — 100к примеров
3. Обучите логистическую регрессию стохастическим градиентным спуском, используя `tf-idf` в качестве факторов. Редкие слова удалите. Проанализируйте, какие слова получили наибольший вес. Попробуйте лемматизировать слова. Нарисуйте `loss` на графике на трейне и на тесте (например, с помощью библиотеки `matplotlib`). Посчитайте метрику `accuracy`, `F-1` (`macro/micro` для задачи мультиклассификации). Для задачи регрессии используйте `MAE`, `MSE`/`RMSE`.
4. Поэкспериментируйте с весом в `L1` регуляризации. Сравните обученную новым способом лог. Регрессию с ранее обученным вариантом. Что лучше? Какие веса занулились? Нарисуйте графики. Посчитайте те же метрики.
5. Обучите нейронную сеть с помощью библиотеки `torch` с одним скрытым слоем, используя `tf-idf` над лемматизированными словами. Редкие слова удалите. Нарисуйте `loss` на трейн и тесте на графике. Сравните лоссы обученные с разными инициализациями: нулевая, `xavier`, `he`. В качестве функции активации используйте `ReLU`. Посчитайте те же метрики.
6. Зафиксируйте лучшее решение по ранее упомянутым метрикам.
7. В случае наличия дополнительных полезных нетекстовых данных для предсказания (площадь жилья, время отправки сообщения и т.п.) попробуйте заиспользовать их в подходе, показавшим наилучшее качество. Напишите, если таких данных в датасете не оказалось.

Датасеты

Egypt Real Estate Listings

<https://disk.yandex.ru/d/kKpsSsg4vmd-vg>

<https://www.kaggle.com/datasets/hassankhaled21/egyptian-real-estate-listings>

Задача: используя текст в `description` предсказать цену (`price`) (задача регрессии)

Financial News Market Events Dataset for NLP 2025

<https://disk.yandex.ru/d/oz3Q060KmBSGnA>

<https://www.kaggle.com/datasets/pratyushpuri/financial-news-market-events-dataset-2025>

предсказать impact level по описанию новости

IMDb 50K Cleaned Movie Reviews

https://disk.yandex.ru/d/k_l-yaY6HKiiwQ

<https://www.kaggle.com/datasets/ibrahimqasimi/imdb-50k-cleaned-movie-reviews>

По отзыву (review / cleaned review) предсказать сентимент (positive / negative)

Twitter Sentiment Analysis

<https://disk.yandex.ru/d/dyJZThGPK2fYsA>

<https://www.kaggle.com/datasets/jp797498e/twitter-entity-sentiment-analysis>

По тексту (tweet content) предсказать sentiment (positive / negative / neutral)

Phishing Email Dataset

<https://disk.yandex.ru/d/XNMme-E55SwplA>

<https://www.kaggle.com/datasets/naserabdullahalam/phishing-email-dataset>

По тексту из body

предсказываем label : 1 (фишинг), 0 — не фишинг

Russian Sentiment Dataset

<https://disk.yandex.ru/d/tFJ0TivvzUt0KA>

<https://www.kaggle.com/datasets/mar1mba/russian-sentiment-dataset>

По тексту предсказать sentiment